

Relatório Técnico-Estratégico: Agente Inteligente para o Setor de Seguro Auto

1. Visão Geral do Projeto e Contexto de Mercado

A transformação do setor de seguros pela Inteligência Artificial atingiu um ponto de inflexão definido pelo "fator escala". Como analisa Chip Huyen em *AI Engineering*, a disciplina evoluiu de um campo esotérico para uma ferramenta de desenvolvimento poderosa baseada em modelos de fundação prontamente disponíveis. A Engenharia de IA no setor de seguros permite transcender os chatbots baseados em fluxos rígidos, criando sistemas que geram valor econômico real através da automação de tarefas complexas que antes exigiam intervenção humana constante. Ao adotar essa abordagem, as seguradoras deixam de focar no treinamento de modelos do zero para se tornarem orquestradoras de inteligência, reduzindo drasticamente o *Time to Market* e focando na resolução de problemas de negócio.

O objetivo central deste projeto é desenvolver um agente assistente consultivo e empático que navegue por todo o ciclo de vida do segurado. Este agente não é apenas uma interface de texto, mas um componente estratégico projetado para:

- **Maximizar a Produtividade Operacional:** Automatizando a triagem de dados e o atendimento de primeiro nível.
- **Elevar a Experiência do Cliente (CX):** Oferecendo suporte imediato e personalizado em momentos de alta sensibilidade.
- **Garantir Eficiência Econômica:** Reduzindo o custo por interação e aumentando a conversão de leads qualificados.
- **Mitigar Riscos de Conformidade:** Assegurando que cada resposta esteja ancorada estritamente nas Condições Gerais da apólice.

A eficácia deste agente depende da resolução de gargalos históricos, como a opacidade dos termos técnicos e a lentidão nos processos de verificação, o que exige uma transição para arquiteturas de IA de última geração.

2. Diagnóstico: Problemas Resolvidos no Ciclo de Seguro Auto

Identificar pontos de fricção no atendimento de seguro auto é fundamental para justificar o ROI em IA. No modelo tradicional, a "sobrecarga cognitiva" e a

latência geram insegurança no segurado, impactando negativamente o NPS e a retenção.

Status Quo (Atendimento Tradicional)	Solução com Agente Inteligente	Métrica de Impacto Esperada
Complexidade: Apólices longas e jargões técnicos.	Clareza: Tradução de termos técnicos via LLM para linguagem acessível.	Aumento de 20% na conversão de renovações.
Latência: Esperas em call centers para dúvidas simples.	Imediatismo: Atendimento instantâneo 24/7 em múltiplos canais.	Redução de 60% no TMA (Tempo Médio de Atendimento).
Inconsistência: Respostas variam por canal ou atendente.	Unificação: Respostas ancoradas em base RAG (Single Source of Truth).	Redução de 40% em reclamações na ouvidoria por erro de informação.
Sinistro Traumático: Processo lento e manual de coleta de dados.	Eficiência (IDP): Extração automática de dados de CNH e fotos via multimodalidade.	Aceleração de 50% na abertura do Aviso de Sinistro (FNOL).

A resolução desses problemas exige uma arquitetura superior aos sistemas baseados em regras, permitindo uma compreensão contextual que diferencia tecnologicamente a seguradora no mercado.

3. Diferenciação Tecnológica: Do Chatbot FAQ ao Agente com RAG

A evolução da IA migrou do processamento de linguagem natural (NLP) tradicional para os Modelos de Fundação. Para o mercado brasileiro, um ponto técnico crítico é a **Tokenização**. Como os tokens são a unidade básica de processamento, em português, termos técnicos de seguros podem ser decompostos

em mais tokens do que em inglês, o que impacta diretamente a latência e o custo das APIs. Um engenheiro de IA sênior deve otimizar o contexto para gerenciar essa eficiência.

1. **Chatbot Tradicional:** Baseado em árvores de decisão e fluxos rígidos. Falha em captar a intenção do usuário fora de trilhas pré-programadas.
2. **Assistente LLM Puro:** Focado em completude (*completion*). Embora fluido, é perigoso para seguros devido ao risco de "alucinações" — gerar coberturas inexistentes baseadas apenas nos pesos probabilísticos do modelo.
3. **Agente com RAG (*Retrieval-Augmented Generation*):** A arquitetura definitiva para o setor. O sistema recupera documentos específicos (Condições Gerais) e os entrega ao modelo como contexto. Isso ancora a resposta em fatos, eliminando a responsabilidade jurídica de alucinações.

O RAG não é apenas uma escolha técnica; é uma estratégia de mitigação de risco legal e comercial indispensável para a confiabilidade necessária em seguros.

4. Arquitetura Conceitual e o Papel do RAG

Uma arquitetura robusta separa o "cérebro" (LLM) do "conhecimento" (RAG). Conforme o *AI Engineering Stack*, isso permite que a base de conhecimento seja atualizada instantaneamente sem o custo proibitivo de retrainar o modelo.

- **Camada de Modelo:** O LLM atua como o motor de raciocínio lógico e linguístico.
- **Camada de Contexto:** Onde reside o banco de vetores e a lógica RAG. Quando o usuário pergunta, o sistema recupera o trecho exato da apólice relevante.
- **Camada de Aplicação:** Gerencia a interface, os gatilhos de segurança e a integração com sistemas legados da seguradora.

O fluxo garante precisão: Pergunta do Usuário -> Recuperação de Documento -> Geração de Resposta Baseada no Documento. Esta arquitetura transforma o agente em um especialista técnico infalível e atualizado.

5. UX Conversacional: Humanização e Alinhamento

O tom de voz é um ativo estratégico, especialmente em sinistros. Para alinhar o agente à marca, não utilizamos supervisão de linguagem natural em tempo real, mas sim **Alinhamento Pós-Treinamento (Post-Training Alignment)** através de

SFT (Supervised Finetuning) e **RLHF (Preference Finetuning)**. Essas técnicas ajustam o comportamento do modelo para seguir as diretrizes de empatia da seguradora.

Diretrizes de UX:

1. **Eliminação de Jargões:** Traduzir "Lucros Cessantes" para "reembolso por dias parados".
2. **Transparência de Identidade:** Declarar-se como assistente de IA, gerindo expectativas.
3. **Reconhecimento de Limites:** Admitir desconhecimento e acionar o transbordo humano imediatamente em casos de alta complexidade.

A humanização estratégica aumenta a retenção, servindo de base para fluxos proativos de negócio.

6. Fluxos Conversacionais Estratégicos

Utilizamos o framework "**Crawl-Walk-Run**" para garantir uma implementação segura:

- **Crawl (FAQ e Dúvidas):** Uso intensivo de RAG para responder sobre coberturas e franquias de forma reativa.
- **Walk (Assistente Interno e Qualificação):** O agente qualifica leads de renovação, coletando perfil de risco e preparando propostas para corretores.
- **Run (Sinistro Autônomo):** Atuação proativa no Aviso de Sinistro, orientando sobre guinchos e fotos, com transbordo automático se detectar sentimento de frustração.

Tratamento de Insegurança: Se o modelo detecta alta complexidade ou estresse severo, gatilhos de *human-in-the-loop* garantem que a transição para o corretor humano seja fluida e contextualizada.

7. Prospecção, Qualificação de Leads e Base de Conhecimento

A eficiência de vendas é impulsionada pelo **IDP (Intelligent Data Processing)**. O agente pode extrair dados estruturados de fontes não estruturadas, como fotos de CNH, comprovantes de residência e orçamentos de oficinas, integrando-os diretamente ao CRM.

Base de Conhecimento Necessária:

- Condições Gerais e Manuais de Produtos.
- Tabelas de Franquias e Redes Credenciadas.
- Documentação de treinamento de vendas (para mimetizar os melhores corretores).

O agente atua como um filtro inteligente, entregando ao time comercial apenas leads com alto potencial de conversão e dados já higienizados.

8. Guardrails, Segurança e Conformidade (LGPD)

A responsabilidade ética é o pilar da confiança. Implementamos **Defensive Prompt Engineering** para proteger a integridade do sistema.

- **Prevenção de Jailbreaking:** Filtros de entrada que barram tentativas de "enganar" o bot para fornecer descontos indevidos.
- **Filtros de PII (Personally Identifiable Information):** Anonimização de dados pessoais antes do envio para APIs de terceiros.
- **Conformidade LGPD:** Garantia de que o tratamento de dados respeita a finalidade contratual e o consentimento do usuário.
- **Guardrails de Saída:** Validação automática para garantir que o bot não faça promessas contratuais fora das normas da SUSEP.
-

9. Métricas de Avaliação e Gestão de Riscos

Avaliar modelos generativos exige uma pipeline sistemática. Adotamos o conceito de **AI as a Judge** (IA como Juiz) para escalar a avaliação: um modelo superior (ex: GPT-4o) avalia as respostas do modelo em produção usando métricas de fidelidade ao contexto e tom de voz.

Métricas Técnicas: Latência, Custo por Token, Perplexidade. **Métricas de Negócio:** Taxa de Deflexão (resolução sem humano), Qualidade dos Leads (MQL).

Risco	Tipo	Ação de Mitigação
-------	------	-------------------

Alucinação de Cobertura	Técnico	Uso obrigatório de RAG e Comparative Evaluation.
Vazamento de Dados	Operacional	Filtros de PII e Gateway de IA seguro.
Rejeição do Usuário	Comercial	SFT/RLHF para alinhamento de tom e transbordo humano proativo.

10. Implementação: MVP e Stack Tecnológica Sugerida

Para equilibrar custo e agilidade, a decisão estratégica é **Buy (Model Layer)** e **Build (Context Layer)**.

- **Modelo (Buy):** LLMs via API para reduzir o Time to Market e escalar com as atualizações globais de inteligência.
- **Contexto (Build):** Desenvolvimento interno do Banco de Vetores para garantir a soberania e segurança dos dados proprietários de seguros.
- **Orquestração:** Frameworks de agentes para gerenciar a memória e o uso de ferramentas externas (APIs de sinistro).

O MVP deve focar em casos de uso de "Baixo Risco/Alto Volume", como o FAQ de coberturas e a cotação inicial.

11. Showcase: Exemplos de Diálogos

Exemplo Negativo (LLM Puro - Falha de Contexto):

Usuário: "Minha apólice cobre retrovisor quebrado em acidente?" **Bot:** "Geralmente, seguros auto cobrem colisões que danificam o veículo. Pode ficar tranquilo que deve estar coberto." *Análise:* O bot alucinou uma garantia genérica, ignorando que o plano "Auto Jovem" deste usuário específico exclui explicitamente vidros e retrovisores na categoria prata.

Exemplo Positivo (Agente com RAG e Raciocínio):

Usuário: "Minha apólice cobre retrovisor quebrado em acidente?" **Bot:** "Sinto muito pelo ocorrido. Analisei sua apólice e, como seu plano é o 'Auto Jovem Prata', a cobertura de vidros e retrovisores não foi contratada. No entanto, você tem um desconto de 20% em nossa rede de oficinas credenciadas. Quer que eu localize a mais próxima?" *Análise:* Resposta baseada em fatos recuperados via RAG, tecnicamente precisa e consultiva.

12. Recomendações Finais

Para transformar este relatório em um projeto de impacto real:

1. **Foco em Avaliação:** Implementar "AI as a Judge" desde o dia 1 para garantir a qualidade.
2. **Dataset Sintético:** Criar diálogos simulados para testar casos de borda em sinistros.
3. **Orquestração:** O papel do Engenheiro de IA agora é menos sobre "treinar" e muito mais sobre "orquestrar e avaliar".

O futuro da engenharia de IA no Brasil exige profissionais que dominem a capacidade de escala dos modelos de fundação, mantendo o rigor ético e a precisão técnica que o setor de seguros demanda.